

Relatório Técnico — HealthSearch

Motor de Busca Híbrido com BM25 e Busca Semântica Vetorial

Tendências em Ciências da Computação

Instituição: UNIPÊ Professor: Me. Ricardo Roberto de Lima

Equipe: Gabriel Xavier, Patrick Sardenbeg, Kevyn Cassiano

1. Arquitetura da solução

O HealthSearch foi implementado em Python com Streamlit. O corpus contém as seis diretrizes médicas definidas no desafio. Na etapa de pré-processamento, os textos são normalizados, tokenizados e filtrados por stopwords em português. O motor lexical utiliza Okapi BM25 com os parâmetros k e b ajustáveis pela interface. O motor semântico utiliza o modelo paraphrase-multilingual-MiniLM-L12-v2 para gerar embeddings e calcula a similaridade de cosseno entre a consulta e os documentos.

2. Fusão híbrida

Os rankings BM25 e semântico são combinados pelo Reciprocal Rank Fusion (RRF). A implementação utiliza $k_{RRF} = 60$ e o parâmetro α controla o peso relativo do ranking BM25. Dessa forma, a solução combina correspondência lexical para termos e códigos exatos com similaridade contextual para consultas com sinônimos ou formulações diferentes.

3. Interface e diagnóstico

A interface possui quatro abas: Léxico — BM25, Semântico, Híbrido — RRF e Matriz Comparativa. A matriz permite observar os rankings produzidos pelos dois motores e pelo método híbrido. Também há gráfico de comparação de ranks e controles laterais para k , b e α .

4. Exemplo de comparação de ranks

Consulta	BM25	Semântico	RRF
ataque cardíaco	ordenação lexical	ordenação contextual	fusão dos rankings
CÓD-ECG-12D	alta precisão lexical	contextual	fusão dos rankings

5. Divisão de tarefas da equipe

Aluno 1 — implementação do pré-processamento e BM25; Aluno 2 — embeddings, similaridade semântica e integração; Aluno 3 — RRF, interface Streamlit, testes e documentação. Caso a equipe tenha dois integrantes, as tarefas podem ser agrupadas entre implementação dos motores e interface/documentação.

Observação: o sistema é um protótipo acadêmico de Recuperação de Informação e não deve ser utilizado como ferramenta de decisão clínica.